

Analiza dostaw kurierskich

Analiza operacyjna i finansowa dostaw rowerowych

Streszczenie

Projekt ten analizował operacyjne i finansowe aspekty dostaw kurierów rowerowych w ramach platformy dostaw, wykorzystując Python, R, analizę statystyczną oraz techniki uczenia maszynowego.

Zbiór danych obejmował dane z 451 dostarczonych zamówień kurierskich w Krakowie w okresie 44 dni od grudnia 2025 do kwietnia 2026 roku. Zmienne operacyjne, finansowe, czasowe i związane z pogodą zostały ręcznie zebrane i zintegrowane w ustrukturyzowanym zbiorze danych analitycznych.

Analiza eksploracyjna ujawniła silne wzorce czasowe i środowiskowe w realizacjach zamówień. Godziny wieczorne przynosiły najwyższe zyski, podczas gdy niekorzystne warunki pogodowe zwiększały trudność operacyjną i czas realizacji dostaw. Dostawy w weekendy przynosiły wyższe średnie zarobki i napiwki w porównaniu do dni powszednich.

Analiza statystyczna potwierdziła, że niektóre zmienne związane z pogodą istotnie wpływały na czas dostawy. Wyniki regresji liniowej wskazywały, że wyższe temperatury wiązały się z krótszym czasem zamówienia, podczas gdy występowanie opadów wykazało nieoczekiwany ujemny związek z czasem dostawy. Jednak model wyjaśniał jedynie ograniczoną część zmienności czasu dostawy, sugerując, że dodatkowe czynniki operacyjne, takie jak warunki na drogach, odległość oraz czas przygotowania zamówienia w restauracji, odgrywają istotną rolę.

Opracowano modele uczenia maszynowego do przewidywania czasu dostarczania. Random Forest przewyższył bazowy model regresji liniowej, zmniejszając średni błąd predykcji do około 7 minut. Pomimo umiarkowanych wyników predykcyjnych, stosunkowo niski wynik R^2 wskazywał, że czas dostawy jest kształtowany przez znaczną rzeczywistą zmienność, która nie została uwzględniona w dostępnym zbiorze danych.

Z biznesowego punktu widzenia analiza sugeruje, że:

- godziny wieczorne stanowią najbardziej dochodowy okres operacyjny,
- warunki pogodowe znacząco wpływają na efektywność kurierów,
- dynamiczne strategie zatrudnienia i zachęty mogłyby poprawić wydajność platformy w trudnych okresach operacyjnych.

Przyszłe ulepszenia mogą obejmować integrację danych GPS o trasach, informacji o ruchu drogowym w czasie rzeczywistym, czasu oczekiwania w restauracji oraz zaawansowanym boostingu algorytmów, aby poprawić dokładność predykcji i analizę operacyjną.

1. Wprowadzenie

Celem tego projektu była analiza czynników wpływających na dochody kurierów oraz efektywność dostaw w miejskich operacjach dostaw żywności.

2. Przegląd zbioru danych

Opis ramki danych

Zbiór danych zawiera 451 dostaw zamówień dostarczonych w ciągu 44 dni roboczych między grudniem 2025 a kwietniem 2026 roku w Krakowie. Po każdej zmianie dane operacyjne były ręcznie rejestrowane, a następnie konwertowane z formatu Excel na CSV. Dane pochodzą z:

- Aplikacji "Glovo Rider": Dane o czasie zamówienia, zyskach i rodzaju dostawy
- <http://meteo.fis.agh.edu.pl/archivalCharts> : Dane pogodowe
- Notatek osobistych: dane o docelowych dzielnicach

Jakie są zmienne w surowych danych:

- CZAS ZAMÓWIENIA
 - **time start**- Czas przyjęcia zamówienia
 - **time end**- Potwierdzenie czasu dostawy
- POGODA
 - **temp**- temperatura w stopniach Celsjusza
 - **fall**- opad w mm/h
 - **wind**- średnia prędkość wiatru w m/s
- WYNAGRODZENIE- w złotych
 - **basic**- wynagrodzenie obliczane na podstawie odległości do partnera, a następnie do klienta. Pokazane pomnożone przez mnożnik zależny od ruchu, który rośnie, jeśli pogoda się pogorszy (opady).
 - **factor**- zależy od ruchu i pogody.
 - **tip**- dodatkowe pieniądze od klienta.
 - **total**- napiwek dodawany do podstawowego zarobku.

Zarobki nie zawierają nagród za wyzwania i korekt dystansu.

TYPE OF DELIVERY (alfabetycznie) - co zamawiają klienci?


animal goods	Towary ze sklepu zoologicznego (w tym karma)
bakery	Pieczyno i produkty z cukierni
breakfast	Potrawy śniadaniowe
burgers	Burgery z lokali wyspecjalizowanych w burgerach
coffee	Kawa z kawiarni
chinese	Potrawy pochodzące z Chin
deli	Gotowe do spożycia lub minimalnie poddawane termicznie (np. podgrzewanie) potrawy, przekąski i półprodukty
fast food	Różne dania, w tym frytki, burgery, nuggetsy, zapiekanki
flowers	Kwiaty i artykuły ze sklepu z pamiątkami
french	Potrawy pochodzące z Francji
groceries	Różne towary kupowane w supermarkecie (głównie żywność)
indian	Potrawy pochodzące z Indii
italian	Potrawy pochodzące z Włoch (z wyjątkiem pizzy)
japanese	Potrawy pochodzące z Japonii
kebab	Kebaby z lokali wyspecjalizowanych w kebabach
korean	Potrawy pochodzące z Korei
liquors	Napoje alkoholowe
mexican	Potrawy pochodzące z Meksyku
pharma	Leki dostępne bez recepty, suplementy, kosmetyki oraz drobne artykuły medyczne
pick up	Usługa transportu drobnych przedmiotów między adresami
pizza	Pizza z pizzerii
polish	Potrawy pochodzące z Polski
portugese	Potrawy pochodzące z Portugalii
salads	Salatki z lokali wyspecjalizowanych w sałatkach
spanish	Potrawy pochodzące z Hiszpanii
tea	Herbaty, głównie bubble tea
turkish	Potrawy pochodzące z Turcji (z wyjątkiem kebabu)
ukrainian	Potrawy pochodzące z Ukrainy
vietnamese	Potrawy pochodzące z Wietnamu

TARGET DISTRICT – gdzie mieszkają klienci?

Dzielnica	Symbol	Dzielnica	Symbol
Stare Miasto	I	Swoszowice	X
Grzegórzki	II	Podgórze Duchackie	XI
Prądnik Czerwony	III	Bieżanów- Prokocim	XII
Prądnik Biały	IV	Podgórze	XIII
Krowodrza	V	Czyżyny	XIV
Bronowice	VI	Mistrzejowice	XV
Zwierzyniec	VII	Bieńczyce	XVI
Dębniki	VIII	Wzgórze Krzesławickie	XVII
Łagiewniki - Borek Fałęcki	IX	Nowa Huta	XVIII

Kurierzy rowerowi mają limit odległości i według niego są przydzielane zamówienia. Działając na Prądniku Czerwonym (północna część miasta), zwiększa się prawdopodobieństwo otrzymania dostaw do pobliskich dzielnic.

Poniższa mapa prezentuje możliwe zasięgi kurierów rowerowych.



W procesie przekształcania danych zostały dodane nowe zmienne:

- **Weekday**- dzień tygodnia
- **Is weekend**- zmienna logiczna; wartość jest TRUE, jeśli zmienna weekday była sobotą lub niedzielą
- **Hour**- godzina akceptacji zamówienia, używana do grupowania zamówień
- **Duration minutes**- czas realizacji zamówienia w minutach
- **Bad weather flag**- zmienna logiczna; wartość jest TRUE, jeśli **przynajmniej jeden** z danych warunków był prawdziwy:
 - $fall > 0$,
 - $temp < 0$ **lub**
 - $wind > 20$

Zrzut ekranu z ramką danych


index ▲	date	weekday	hour	time_start	time_end	duration_minutes	temp	fall	wind	bad_weather_flag	basic	factor	tip	total	type	target	tar_sym	is_weekend
0	2025-12-02	Tuesday	9	09:04:00	09:46:00	42	1.0	0.0	1.0	false	18.05	1.69	0.0	18.05	breakfast	Stare Miasto	I	false
1	2025-12-02	Tuesday	9	09:46:00	10:19:00	33	1.0	0.0	1.8	false	12.19	1.69	0.0	12.19	breakfast	Podgórze	XIII	false
2	2025-12-02	Tuesday	10	10:20:00	11:04:00	44	1.5	0.0	0.9	false	14.34	1.52	0.0	14.34	coffee	Krowodrza	V	false
3	2025-12-02	Tuesday	11	11:50:00	12:17:00	27	2.0	0.0	1.7	false	11.55	1.67	2.25	13.8	vietnamese	Prądnik Biały	IV	false
4	2025-12-02	Tuesday	12	12:17:00	13:02:00	45	2.5	0.0	1.2	false	17.53	1.97	0.0	17.53	groceries	Bronowice	VI	false
5	2025-12-02	Tuesday	13	13:02:00	13:43:00	41	2.5	0.0	1.5	false	17.63	2.2	0.0	17.63	liquors	Zwierzyniec	VII	false
6	2025-12-02	Tuesday	17	17:06:00	17:52:00	46	2.5	0.0	0.6	false	14.69	2.2	0.0	14.69	pizza	Stare Miasto	I	false
7	2025-12-02	Tuesday	17	17:52:00	18:22:00	30	2.0	0.0	0.8	false	18.8	2.2	0.0	18.8	fast food	Grzegorzki	II	false
8	2025-12-02	Tuesday	18	18:43:00	19:39:00	56	1.6	0.0	0.9	false	22.37	2.2	0.0	22.37	burgers	Prądnik Czerwony	III	false
9	2025-12-02	Tuesday	18	18:56:00	19:45:00	49	1.6	0.0	0.8	false	11.91	2.2	3.98	15.89	tea	Prądnik Czerwony	III	false
10	2025-12-04	Thursday	9	09:01:00	09:31:00	30	0.0	0.0	1.2	false	9.5	1.41	0.0	9.5	groceries	Prądnik Czerwony	III	false
11	2025-12-04	Thursday	9	09:31:00	09:51:00	20	1.0	0.0	0.7	false	8.84	1.41	0.0	8.84	groceries	Prądnik Czerwony	III	false
12	2025-12-04	Thursday	9	09:51:00	10:09:00	18	1.8	0.0	0.8	false	10.27	1.41	0.0	10.27	fast food	Prądnik Czerwony	III	false
13	2025-12-04	Thursday	10	10:55:00	11:18:00	23	2.9	0.0	1.3	false	10.14	1.41	0.0	10.14	flowers	Prądnik Czerwony	III	false
14	2025-12-04	Thursday	11	11:27:00	11:57:00	30	4.0	0.0	1.4	false	11.96	1.56	0.0	11.96	italian	Prądnik Biały	IV	false
15	2025-12-04	Thursday	11	11:57:00	12:18:00	21	4.8	0.0	0.3	false	8.44	1.56	0.0	8.44	groceries	Prądnik Czerwony	III	false
16	2025-12-04	Thursday	12	12:19:00	13:01:00	42	4.9	0.0	0.4	false	21.06	1.88	3.79	24.85	kebab	Krowodrza	V	false
17	2025-12-04	Thursday	13	13:07:00	13:56:00	49	5.2	0.0	0.9	false	20.16	2.03	0.0	20.16	pizza	Stare Miasto	I	false
18	2025-12-04	Thursday	13	13:56:00	14:27:00	31	3.8	0.0	0.8	false	19.13	2.03	0.0	19.13	fast food	Krowodrza	V	false
19	2025-12-04	Thursday	17	17:00:00	17:30:00	30	1.6	0.0	0.5	false	17.21	2.14	0.0	17.21	pizza	Stare Miasto	I	false
20	2025-12-04	Thursday	17	17:30:00	18:06:00	36	1.3	0.0	0.3	false	14.37	2.14	0.0	14.37	deli	Krowodrza	V	false
21	2025-12-04	Thursday	18	18:06:00	18:31:00	25	1.5	0.0	0.4	false	14.03	2.18	0.0	14.03	fast food	Zwierzyniec	VII	false

3. Eksploracyjna analiza danych


KPI

KPI	Wartość
Dostarczone zamówienia	451
Średni czas zamówienia	29 min
Średnie zarobki (za zamówienie)	13 PLN
Średni napiwek	0,62 PLN
Dni operacyjne	44 dni

Rozkłady




Aplikacja dostaw działa od 7:00 do 4:00 następnego dnia. Sloty zmian kurierskich najczęściej były dostępne wczesnym rankiem i wieczorem. Między 12 a 14 zazwyczaj miałam przerwę na lunch po 3-4 godzinach intensywnej jazdy. Sesje popołudniowe i wieczorne zazwyczaj oferowały wyższe wartości mnożnika, a co za tym idzie wyższe zyski.




Pomimo, że mnożnik był stosunkowo niski o 7 rano, to zmniejszona dostępność kurierów zwiększała prawdopodobieństwo otrzymania dostaw dalekobieżnych. Zyski stopniowo rosły przez całe popołudnie i osiągały szczyt w godzinach wieczornych.

Weekend vs dni robocze




Weekendy są bardziej opłacalne niż praca w dni powszednie.

Analiza pogodowa




Zaobserwowano wyższą średnią wartość napiwku podczas sprzyjających warunków pogodowych. Do wyjaśnienia tego wzorca potrzebna byłaby dalsza analiza behawioralna.




Głównym czynnikiem w tym zbiorze danych jest zmienna `total` (zarobek z napiwkiem), która wykazuje najsilniejsze (umiarkowane) korelacje z wysokością napiwku i czasem trwania. Czynniki pogodowe mają znikomy lub bardzo słaby wpływ na zmienne finansowe i czasowe.

Analiza napiwków




Godziny wieczorne generują najwięcej napiwków.

Zarobki na godzinę




Najbardziej opłacalne są godziny od późnego popołudnia/wczesnego wieczora (15-20:00). Przyzwoite wyniki również są w południe (12-13:00).


Analiza geograficzna



Jedynym łącznikiem między zarobkami a lokalizacją jest odległość między kurierem a klientem. Jak zostało wspomniane wcześniej- działanie w jednej dzielnicy zwiększa prawdopodobieństwo otrzymania dostaw do sąsiednich okolic.



Byłam na Podgórzu, gdy pojawiło się zamówienie do Bieżanowa-Prokocimia. Prawdopodobnie przyczyniło się to do stosunkowo krótkiego średniego czasu dostawy zaobserwowanego w tej dzielnicy.



Duże sieci fast-foodowe wprowadzają wiele kuponów do wykorzystania w aplikacjach platform dostaw. Większość mieszkańców miasta zamawia dania fast foodowe. Na obrzeżach najczęściej zamawia się zakupy spożywcze.

4. Analiza statystyczna

Hipoteza I:

Zyski w weekendy są wyższe niż w pozostałe dni powszednie

is_weekend	avg_total	avg_duration
<lgl>	<dbl>	<dbl>
FALSE	12.89598	28.57474
TRUE	14.71889	28.31746

T-test

$t = -2,8439$, $df = 74,177$, $p\text{-wartość} = 0,005756$

Dostawy w weekendy generowały znacząco wyższe zarobki w porównaniu z dniami powszednimi ($p < 0,05$).

Hipoteza II:

Czas trwania dostawy zależy od warunków pogodowych.

Regresja liniowa

Residual standard error: 9.483 on 445 degrees of freedom
Multiple R-squared: 0.03962,
Adjusted R-squared: 0.02883
F-statistic: 3.671 on 5 and 445 DF,
p-value: 0.002886

Analiza regresji liniowej wykazała, że temperatura i opady są statystycznie istotnymi predyktorami czasu dostawy. Wyższe temperatury wiązały się z krótszym czasem dostawy, podczas gdy opady niespodziewanie wykazały negatywny związek z czasem trwania. Inne zmienne, takie jak prędkość wiatru, status weekendu i mnożnik, nie były statystycznie istotnymi predyktorami.

Pomimo istotności statystycznej, model wyjaśnił jedynie niewielką część zmienności czasu dostawy ($R^2 \approx 0,04$), sugerując, że dodatkowe czynniki operacyjne, takie jak warunki ruchu i trasa, prawdopodobnie odgrywają dużą rolę.

Hipoteza III:

Czas trwania dostawy zależy od części dnia

ANOVA

	Df	Sum Sq	Średni Sq	wartość F	Pr(>F)
Czynnik(godzina)	14	1257	89.81	0.969	0.0484
Pozostałości	436	40413	92.69		

Pomimo widocznych różnic w godzinach, wyniki ANOVA nie wykazały statystycznie istotnych różnic w średnim czasie dostawy.

Wydaje się, że czas dostawy zależy bardziej od czynników operacyjnych i środowiskowych niż od samej pory dnia.

5. Uczenie maszynowe

Celem sekcji uczenia maszynowego było zidentyfikowanie czynników wpływających na czas realizacji oraz ocena wydajności modelu predykcyjnego. Użyto następujących zmiennych:

- Czas
- Temperatura
- Prędkość wiatru
- Intensywność opadów
- Mnożnik
- Dzień tygodnia
- Dzielnica
- Rodzaj dostawy

W tym przypadku zastosowano model regresji liniowej oraz model Random forest. Wyniki ewaluacji przedstawiono w poniższej tabeli.

Ewaluacja

Model	MAE	RMSE	R ²
Regresja liniowa	7.6	9.9	-0.08
Random Forest	7.0	9.1	0.08


Podsumowanie

Model Random Forest przewyższył bazowy model regresji liniowej, redukując średni błąd predykcji do około 7 minut.

Weryfikacja krzyżowa potwierdziła stabilną wydajność modelu w różnych podziałach testów train-test.

Jednak stosunkowo niski wynik R² sugeruje, że czas trwania dostawy zależy od dodatkowych czynników zewnętrznych, które nie uwzględniono w zbiorze danych.

Wykres Feature Importance



Najbardziej wpływowe cechy w przewidywaniu czasu dostawy to temperatura, prędkość wiatru oraz wartość mnożnika.

6. Wnioski

Projekt ten analizował operacyjne i finansowe aspekty dostaw kurierów rowerowych z wykorzystaniem języka Python, R oraz uczenia maszynowego.

Analiza wykazała, że efektywność dostaw zależy w dużej mierze od wzorców pory dnia i warunków pogodowych. Godziny wieczorne przynosiły najwyższe zyski, podczas gdy niektóre niekorzystne warunki pogodowe wydłużały czas dostaw i wydłużały trudności operacyjne.

Modele uczenia maszynowego osiągały umiarkowane wyniki predykcyjne, a Random Forest przewyższał bazowy model regresji. Stosunkowo niski wynik R^2 sugeruje, że czas trwania dostawy jest zależny od dodatkowych zmiennych zewnętrznych, które nie uwzględniają w zbiorze danych, takich jak warunki drogowe czy czas oczekiwania na zamówienie.

Z perspektywy biznesowej wyniki sugerują, że dynamiczne strategie zatrudnienia i premie za pracę w niekorzystnych warunkach pogodowych mogą poprawić efektywność kurierów i wydajność platformy.

Przyszłe ulepszenia mogą obejmować dane geograficzne na poziomie tras oraz zaawansowany boosting algorytmów zwiększające dokładność predykcji.

7. Przyszłe udoskonalenia

Niektóre ulepszenia można wprowadzić w kolejnych wersjach projektu:

- Dane o ruchu na drogach,
- Długość trasy,
- Zaawansowany boosting algorytmów,
- Mierzony czas w restauracji