




Analiza dostaw kurierskich

Analiza operacyjna i finansowa dostaw rowerowych

Autor: Magdalena Bałabańska

- 
- 
- **Narzędzia:** Python, R, Power BI
 - **Zbiór danych:** 451 zamówień dostarczonych w Krakowie



Cel projektu

Celem projektu była analiza operacyjnych i finansowych aspektów dostaw kurierów rowerowych.

Analiza koncentrowała się na:

- efektywności dostaw,
- wzorcach zysków,
- wpływie pogody,
- zachowaniach klientów (np. napiwki, typ dostaw),
- prognozowaniu czasu dostawy z wykorzystaniem uczenia maszynowego.



Przegląd danych

Charakterystyka zbioru danych

- 451 dostarczone zamówienia
- 44 dni operacyjne
- Lokalizacja: Kraków
- Czas obserwacji: Grudzień 2025 - Kwiecień 2026

Źródła danych

- Aplikacja Glovo Rider
- Archiwalne dane pogodowe
- Dodatkowe dane z notatek osobistych



Przegląd danych

Kluczowe zmienne

- Zarobki (basic i total)
- Napiwki (tip)
- Czas zamówienia (duration, time start, time end)
- Dzielnica (target)
- Zmienne pogodowe (temp, fall, wind)
- Mnożnik (factor)
- Godzina (hour)



Przygotowanie danych

Dodano zmienne:

- duration_minutes
- is_weekend
- bad_weather_flag
- hour

Czyszczenie danych

- Wystandardyzowanie zmiennej czasowej
- Przekształcenie zmiennych kategorycznej
- Przygotowanie danych do wykorzystania w modelach uczenia maszynowego




Analiza eksploracyjna


Kluczowe pytania

- Kiedy są najwyższe zarobki?
- Jak pogoda wpływa na dostawy?
- Które dzielnice Krakowa są najbardziej efektywne operacyjnie?
- Jak zmienia się zapotrzebowanie w ciągu dnia?


Średnie zarobki za zamówienie




Liczba zamówień w ciągu dnia




Weekend vs dzień roboczy (zarobki za zamówienie)



Macierz korelacji



Zarobki w dzielnicach





Wgląd operacyjny

Kluczowe wnioski

- Godziny wieczorne generowały najwyższe zarobki.
- Popyt na dostawy znacznie wzrastał w godzinach popołudniowych i wieczornych.
- Zmiany weekendowe przyniosły wyższe średnie zarobki.
- Niekorzystne warunki pogodowe wydłużały czas dostawy.



Analiza statystyczna

Użyte metody:

- ANOVA
- Regresja liniowa
- Analiza korelacji

Wyniki:

- Temperatura miała istotny wpływ na czas dostawy.
- Warunki pogodowe miały wpływ na wydajność operacyjną.
- Zmienność operacyjna pozostała stosunkowo wysoka.

Analiza statystyczna

Współczynniki regresji:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	31.8388	2.5037	12.717	< 2e-16 ***
wind	0.6132	0.4117	1.489	0.13707
temp	-0.2930	0.1007	-2.908	0.00382 **
fall	-3.8449	1.5471	-2.485	0.01332 *
factor	-0.8093	1.1186	-0.723	0.46976
is_weekend TRUE	-0.7047	1.3305	-0.530	0.59662



Machine Learning

Cel:

- Prognoza czasu dostawy z użyciem zmiennych operacyjnych i związanych z pogodą.

Modele:

- Regresja liniowa
- Random forest

Parametry ewaluacyjne:

- MAE
- RMSE
- R^2


Ocena modeli

Model	MAE	RMSE	R ²
Random Forest	7.01	9.18	0.08
Regresja liniowa	7.61	9.94	-0.08


► Interpretacja

- Random Forest wykazał lepsze wyniki niż regresja liniowa.
- Błąd predykcji pozostał stosunkowo wysoki.
- Niski współczynnik R² sugeruje znaczną zmienność operacyjną.

Wykres Feature Importance



Prognoza vs rzeczywistość





Rekomendacje biznesowe

Zalecenia operacyjne:

- Zwiększenie dostępności kurierów w godzinach szczytu wieczornego.
- Wprowadzenie systemów motywacyjnych uzależnionych od pogody.
- Optymalizacja dostępności slotów w okresach wzmożonego zapotrzebowania.
- Monitorowanie efektywności operacyjnej na poziomie dystryktu.

Przyszłe usprawnienia:

- Integracja tras GPS
- Dane o ruchu drogowym w czasie rzeczywistym
- Analiza czasu oczekiwania w restauracji
- Zaawansowana optymalizacja modeli

Zobacz dashboard w PowerBI!



Content


KPI

Operations

ML

Insights

Zobacz dashboard w PowerBI!






Podsumowanie

Wnioski końcowe

- Dostawy w dużym stopniu zależą od czasu i warunków pogodowych.
- Godziny wieczorne są najbardziej efektywne operacyjnie.
- Modele uczenia maszynowego wykazały umiarkowaną skuteczność predykcyjną.
- Rzeczywiste dostawy charakteryzują się znaczną zmiennością.



Zaprezentowane umiejętności

- Czyszczenie danych
 - Analiza eksploracyjna
 - Analiza statystyczna
 - Uczenie maszynowe
 - Business Intelligence
 - Wizualizacja danych
- 



Dziękuję za uwagę

Contact

- GitHub: [magdus-data-science](https://github.com/magdus-data-science)
- LinkedIn: [Magdalena Bałabańska](#)
- Email: m.balabanska93@gmail.com